




TESCAN MASTER TEMPLATE



Machine Learning v Pythonu

Kateřina Vrána

Kdo vede tento workshop

- ➔ Tescan je česká technologická firma zaměřená na elektronovou mikroskopii a vědecké přístroje
- ➔ Vyvíjíme technologie, které pomáhají zkoumat svět na úrovni mikrometrů a nanometrů
- ➔ Propojujeme fyziku, software, strojírenství a AI v reálných produktech pro vědu i průmysl
- ➔ Naše technologie používají univerzity, výzkumné ústavy i špičkové firmy po celém světě



Kateřina Vrána

**Global AI/ML Coordinator &
Senior ML Engineer**

Absolventka FIT VUT, obor
Počítačová grafika a multimedia
katerina.vrana@tescan.com

Co byste si měli odnést?


- Znalost některých základních pojmů a souvislostí.
- Matematický základ, na kterém to všechno stojí.
- Základní intuici jak to funguje a proč.
- Představu k čemu to je v praxi.
- Tipy jak můžete ML dělat i vy.
- **Inspiraci a dobrý pocit :)**

Co byste si měli odnést?

- Znalost některých základních pojmů a souvislostí.
- Matematický základ, na kterém to všechno stojí.
- Základní intuici jak to funguje a proč.
- Představu k čemu to je v praxi.
- Tipy jak můžete ML dělat i vy.
- **Inspiraci a dobrý pocit :)**

Co nás čeká


➔ 01	Úvod do teorie – ML, neuronová síť, funkce, derivace...
➔ 02	Příklad 1 – Regrese v Pytorchu
➔ 03	Příklad 2 – Multifeatured data v Pytorchu
➔ 04	ML projekty v Tescanu



01

Úvod do teorie

Umělá inteligence a další pojmy



<https://idaho.pressbooks.pub/app/uploads/sites/101/2024/10/Screenshot-2025-02-04-at-9.18.44%E2%80%AFPM-1024x676.png>


Co je to $f(x)$?

Funkce – opakování?

- Jaké známe funkce z reálného světa?
- Co funkce dělá?

$$f(x) = c$$

x	$f(x)$
0	c
2	c



Funkce – co na to chatboti?

Vyjmenuj 3 příklady různých reálných spojitých funkcí z běžného života teenagerů v roce 2026.

1. Čas strávený učením a míra zapamatování

Funkce:

$f(\text{čas učení}) = \text{míra zapamatování}$

S delší dobou soustředěného učení si teenager většinou zapamatuje více, ale po určité době už se zlepšení zpomaluje.

2. Jas displeje telefonu a výdrž baterie

Funkce:

$f(\text{jas displeje}) = \text{výdrž baterie}$

Čím vyšší jas displeje teenager používá, tím rychleji se baterie vybíjí a celková výdrž telefonu klesá.

3. Doba cvičení a tepová frekvence

Funkce:

$f(\text{doba cvičení}) = \text{tepová frekvence}$

Při delším cvičení tep teenagera obvykle roste plynule, dokud se nepřiblíží stabilnější zátěžové hodnotě.



Funkce matematictěji

- **Funkce je převod nějakého vstupu na nějaký výstup**
- Definice funkce (tabulka, rovnice, graf, slovní definice, kód v programovacím jazyku...).
- Musí být jednoznačná (jeden vstup = jeden výstup!)

Proměnná, vstupy, výstupy...

- Proměnná $x_{i,j}$, $w_{i,j,k}$, $y...$
- Co je co – vstup, výstup, jméno funkce

$$y = g(x_{i,j})$$
$$\text{secti}(a, b) = a + b$$

- Dva vstupy? Je to v pořádku?

Složitější funkce

- Některé užitečné funkce mají svůj speciální zápis

$$\sum_{j=1}^M w_j = w_1 + w_2 + \cdots + w_M$$

$$\text{suma}(w_1, w_2, \dots, w_M) = w_1 + w_2 + \cdots + w_M$$

Funkce – co s nimi můžeme dělat?

- Můžeme je skládat: $g(x_1, x_2) = h(f(x_1, x_2))$

$$\textit{prictijedna}(x) = x + 1$$



$$\textit{vynasobprictijedna}(x_1, x_2) = \textit{prictijedna}(\textit{vynasob}(x_1, x_2))$$

$$\textit{vynasobprictijedna}(x_1, x_2) = x_1 \cdot x_2 + 1$$


Funkce – co s nimi můžeme dělat?

- Můžeme je derivovat.
- Ale jen pokud splňují některé podmínky.
- **Derivace udává směr funkce v bodě.**

Derivace - intuitivně




Neuronová síť – co tam vidíme?



Umělý neuron

- Základní stavební blok neuronové sítě
- Umělý neuron lze vyjádřit funkcí
- Můžeme s ním dělat to, co s funkcemi




Neuronová síť – skládání funkcí

- Neuronovou síť lze vyjádřit složenou funkcí

$$y = g(x_{2,1})$$


?



Neuronová síť – skládání funkcí

Dosadíme $x_{2,1} = \sum_{j=1}^J w_{2,j,1} a_{1,j}$,
dostaneme $y = g(\sum_{j=1}^J w_{2,j,1} a_{1,j})$

$y = g(x_{2,1})$




Neuronová síť – skládání funkcí

$y = g(x_{2,1})$


Dosadíme $x_{2,1} = \sum_{j=1}^J w_{2,j,1} a_{1,j}$,
dostaneme $y = g(\sum_{j=1}^J w_{2,j,1} a_{1,j})$

Dosadíme $a_{1,j} = f_j(x_{1,j})$,
dostaneme $y = g(\sum_{j=1}^J w_{2,j,1} f_j(x_{1,j}))$




Neuronová síť – skládání funkcí

$$\begin{aligned} & y = g(x_{2,1}) \\ \text{Dosadíme } x_{2,1} = \sum_{j=1}^J w_{2,j,1} a_{1,j}, & \text{ dostaneme } y = g\left(\sum_{j=1}^J w_{2,j,1} a_{1,j}\right) \\ \text{Dosadíme } a_{1,j} = f_j(x_{1,j}), & \text{ dostaneme } y = g\left(\sum_{j=1}^J w_{2,j,1} f_j(x_{1,j})\right) \\ \text{Dosadíme } x_{1,j} = \sum_{n=1}^N w_{1,n,j} x_{0,n}, & \text{ dostaneme } y = g\left(\sum_{j=1}^J w_{2,j,1} f_j\left(\sum_{n=1}^N w_{1,n,j} x_{0,n}\right)\right) \end{aligned}$$



Neuronová síť lze vyjádřit funkcí

- Různý způsob zápisu, stejná síť



$$x_{0,n} \Rightarrow g\left(\sum_{j=1}^J w_{2,j,1} f_j\left(\sum_{n=1}^N w_{1,n,j} x_{0,n}\right)\right) \Rightarrow y$$

Machine learning – jak se to teda učí?

- Jak se učíme my?

Machine learning – jak se to teda učí?

- Jak se učíme my?
- Pokus – chyba – oprava – opakování

Machine learning – jak se to teda učí?

- Jak se učí neuronovky?

Machine learning – jak se to teda učí?

- **Pokus**


Potřebujeme vstupy – x_n
Spočítáme výstup – y

Machine learning – jak se to teda učí?

- **Chyba**
- Potřebujeme ukázkový správný výstup („label“) $\hat{y}$
- Chybu l nám udává chybová funkce:


$$l = L(y, \hat{y})$$

$$\text{loss}(\text{vystup_site}, \text{spravny_vystup})$$



Machine learning – jak se to teda učí?

- **Oprava**
- Upravíme váhy sítě, aby to příště vyšlo lépe 😊
- Na to musíme umět derivovat 😞




Derivace pro učení neuronových sítí

- **Derivace udává směr funkce v bodě**
- **Gradient je „sada“ čísel - všechny derivace pro všechny naše váhy**
- **Příklad:**
 - Loss funkce „zabaluje“ neuronovku s dvěma váhami w_1 w_2 .
 - Výstup sítě y vyšel 10, očekávaný výstup $\hat{y}$ má být 15.
 - Gradient může vypadat takto: $\nabla L(10, 15) = (2, 3)$.
 - Derivace podle váhy w_1 je 2, derivace podle váhy w_2 je 3.


Machine learning – jak se to teda učí?

- Chybu jsme si vyjádřili funkcí
- Jsme v bodě daném současným nastavením vah
- Spočítáme směr růstu - gradient
- **Upravíme váhy krokem proti směru gradientu**




Gradientní sestup

- Toto musíme udělat mockrát dokola
- **Říká se tomu gradientní sestup**
- Gradientní sestup pro jednu váhu




Gradientní sestup

- Gradientní sestup pro dvě váhy



Rekapitulace – co si mám pamatovat?

- **Neuronová síť je funkce**
- **Chyba** je dána **chybovou funkcí**
- **Derivace** udává **směr funkce** v bodě
- **Gradient** chybové funkce je **sada derivací** podle všech vah
- **Gradient chybové funkce** udává **směr chybové funkce**
- **Pro natrénování neuronové sítě musíme jít po chybové funkci směrem dolů**



02

Příklad 1


Regrese v Pytorch


Ukázka 1

- Zobrazení funkce a její derivace
- Příklad použití funkce a její derivace
- Příklad lineární a nelineární regrese s knihovnou Pytorch

Ukázka 1

- Otevřete si v Chrome prohlížeči stránku <https://github.com/Travnickt3d/FITLS/tree/main/2026>
- Otevřete si dokument Instructions.pdf






03

Příklad 2

Multifeatured data v Pytorch



04



ML projekty v Tescanu

Machine Learning tým v Tescanu



Začátek ML projektu

- **Vznikne požadavek na funkcionalitu**
- „Chci, aby uživatel dentální aplikace nemusel naklikávat pozici nervu v čelisti ručně“
- „Chci, aby mi mikroskop našel zajímavá místa ve vzorku“



Specifikace požadavku

- **Zadavatel s ML inženýrem vydefinují formální specifikaci pro vývoj**
- Jak vypadají vstupní data? Jsou to obrázky? 3D skeny? Něco jiného?
- Kolik dat máme pro trénování? Potřebujeme nasbírat další?
- Jak vypadá správný výstup? Máme labely nebo musíme vytvořit?
- Jak budeme měřit úspěšnost? Jaký typ hodnot (metrika) a jaké hodnoty považujeme za dostatečné?
- Jak a kam se to pak zapojí? Webová služba? Aplikace běžící na mikroskopu?

Analýza proveditelnosti

- **ML inženýr začne hledat řešení**
- Prověří existující řešení
- Přečte si související odborné články
- Nalezne nebo vytvoří základní implementaci řešení a udělá pár experimentů
- **Výstupem je rozhodnutí, zda úlohu dokážeme řešit a jak náročné to bude**

Prototypování/trénování modelu

- **ML inženýr pracuje na první plně použitelné verzi modelu**
- Pouští trénování s různými nastavením
- Sleduje, jak dobře vypadají výstupy a metriky
- **Výstupem je nejlepší natrénovaný model**


Current deploy candidate:

CTTeethDetSegAuto3Dv4.2-alpha0-0001_2023_0317_1824

- TP percentage MAX: 99.29 %
- Success percentage: 92.51 %
- Combined: 91.85 %
- Iteration: 246 000


Average results on full cases inference (Validation set)

- TP percentage = true positive landmarks with activation threshold > 0.1
- Success percentage = percentage of TP landmarks with distance error < 3 mm







Nasazení modelu

- **Příprava modelu pro reálné použití**
- Integrace do aplikace, nasazení na serveru...
- Testování celé funkcionality a úpravy finálního řešení
- **Výstupem je nová nebo vylepšená funkcionality, kterou může používat koncový uživatel**




Naše data

- Zubařské CT skeny čelistí pacienta (3D objemová data)
- Skeny zubů vytvořené intraorálním skenerem (povrchová data)
- Data z elektronových mikroskopů (3D objemová nebo obrázky)
- CT skeny z mikro CT (3D objemová data)




Naše projekty – trasování nervu

- Vstupem neuronovky je řez kolmý na nerv.
- Výstupem je detekovaná pozice nervu.




Naše projekty – segmetnace CT zubů

- Segmentační „pipeline“ – detekce pozic zubů a segmetnace tvaru zubů



Naše projekty – Zarovnání zubů do ideálního oblouku

- Vstupem je povrchový model křivých zubů
- Výstupem jsou automaticky navržené nové pozice zubů





Naše projekty – Automatické vyjmutí lamely

- Zapojené přímo v SW ovládajícím mikroskop
- Automatizované workflow pro vyříznutí velmi tenké destičky ze vzorku



Naše projekty – Odstranění šumu v mikro CT datech

- Vstupem jsou CT data, ve kterých je šum. (Prakticky v každých nějaký je.)
- Výstupem jsou méně zašuměná data.




Co můžete dělat vy?

- Nebát se matematiky a technických oborů.
- Prohledat internety - **Tutoriály na Python, Keras, PyTorch...**
- Koukat na YouTube: **Two Minute Papers, Alfredo Canziani...**
- Soutěžit v **Středoškolská odborná činnost** v oboru informatika

Co můžete dělat vy?

- Jít studovat na FIT VUT ☺



Tescan

Thank you

